
Traduction des Langages

Cours de Christine MAUREL

Christine.Maurel@irit.fr

Mattijs KORPERSHOEK

mattijs.korpershoek@univ-tlse3.fr

M1 Informatique, Université Paul Sabatier

Année 2012 - 2013

Ceci est un cours pris par moi-même.

Il a été relu mais peut quand même comporter des inexactitudes ou des erreurs.

En aucune façon, ce document ne prétend remplacer "le plaisir d'aller écouter le cours raconté par la dame même à 7h45 le vendredi"

Table des matières

1	Introduction	3
1.1	Définitions	3
1.2	Phases de la compilation	4
2	Analyse Lexicale	5
2.0.1	Expressions régulières	6
2.0.2	Constantes numériques	6
2.0.3	Scanner	6
2.1	Exemples et rappels de L3	6
2.2	Décorer l'automate fini avec des actions sémantiques	7
2.3	Rappels	8
2.4	Quelques problèmes à régler	8
2.4.1	Problèmes de reconnaissance	8
2.4.2	Table des Symboles (TDS)	9
2.4.3	Problème du recul	9
2.5	La notion de surlangage	10
2.5.1	Pour automatiser les scanners	12
2.6	Rappels sur les grammaires	13
2.7	Approximation successive	14
3	Notion d'analyse syntaxique	16
3.1	Analyse descendante	18
3.2	$First_k$	19
3.3	$Follow_k$	21
3.4	$k.lookahead$	22
3.5	$LL(k)$	23
3.6	Table d'analyse d'une grammaire $LL(k)$	24
3.7	Résultats théoriques	25
3.8	Procédures de descente récursive	25
3.8.1	Définitions	25
3.8.2	Exemple	27
3.9	Éliminer la récursivité à gauche	28
3.9.1	Pour essayer d'éliminer la récursivité à gauche	29

4	Génération de code	32
4.1	Introduction	32
4.2	Langage intermédiaire des quadruplets	32
4.3	Actions sémantiques couplées à l'analyseur descendant	33
4.4	Methodologie pour la traduction des structures de controle	35
4.4.1	Rappels	35
4.4.2	Exemple de traduction sur ifstat	36
4.4.3	Exemple de traduction sur whilestat	37
4.4.4	Traduction de déclarations	39
4.4.5	Conclusion sur les actions sémantiques couplées avec analyse syntaxique $LL(1)$	41
4.5	analyse ascendante	42
4.5.1	Definitions	42
4.5.2	Exemple	43
4.5.3	automatiser ce type d'analyse	44
4.5.4	Exemple d'analyseur $LR(1)$	45
4.6	Piles syntaxiques et sémantiques	47
4.6.1	Exemple avec pile sémantique	48

Chapitre 1

Introduction

Le but est de nous faire comprendre comment fonctionne la traduction des langages haut niveau en langage machine. (ie compris par la machine, en binaire)

Comblent le fossé sémantique. logiciels :

interprété $P \rightarrow \text{interprete} \rightarrow \text{résultat du calcul}$

compilé $P \rightarrow \text{compilateur} \rightarrow \text{Programme } P'$


Interpreter, c'est Lire ; \rightarrow Evaluer ; \rightarrow Imprimer ;

1.1 Définitions

- Un interprete c'est *un programme qui simule la machine cible*
- Un compilateur c'est un *transformateur/traducteur* de programme

Note : il est important d'avoir *équivalence* entre P et P' , ça nécessite de certifier la traduction. (voir 1.1)

FIGURE 1.1– Différences entre compilation et interpretation




Interprété Convivial, rapidité de la mise au point. Inconv : efficacité.

Compilé Efficacité, Inconv : lourd, rigide

1.2 Phases de la compilation

voir 1.2

FIGURE 1.2– Schéma compilation



Analyse lexicale

Unité syntaxique détection d'erreurs syntaxiques

Analyse syntaxique


Génération de code

Chapitre 2

Analyse Lexicale

La première phase de la chaîne de compilation. Il s'agit de passer de la *syntaxe concrète* à la *syntaxe abstraite*. C'est pour éliminer le "sucre syntaxique"

FIGURE 2.1– analyse lexicale



Scanner l'outil qui réalise l'analyse lexicale

Parser l'outil qui réalise l'analyse syntaxique

Exemple :

Listing 2.1– Exemple de code analysé

```
begin /* Retour a la ligne */  
  X := 4;  
end
```

Mots clés begin end if then else

Identificateur de variable X

Opérateur :=

Constante numérique 4

Séparateurs ; retour à la ligne

Lexème

- Les identificateurs doivent commencer par une *lettre* suivie d’une suite éventuellement vide de lettres, chiffres et éventuellement de caractères spéciaux

2.0.1 Expressions régulières

$$l \in \{a, \dots, z, A, \dots, Z\}$$

$$c \in \{0, \dots, 9\}$$

$l(l + c)^* \rightarrow$ Théorème d’Arden \rightarrow automate fini *déterministe*.

2.0.2 Constantes numériques

Suite *non vide* de chiffres. Rappel :

$$cc^* \equiv c^+$$

Automate fini déterministe.

2.0.3 Scanner

C’est un automate fini déterministe construit de façon rigoureuse avec le théorème d’Arden pour reconnaître les différentes unités syntaxiques du langage compilé.

Il faut parfois avoir des informations associées aux unités syntaxiques, celles ci sont nommées les *attributs sémantiques*. Par exemple, la valeur décimale d’une constante numérique, la chaîne de caractères pour un identificateur.

Pour calculer ces attributs, on décore les transitions de l’automate fini avec des *actions sémantiques*.

2.1 Exemples et rappels de L3

Exemple de construction de scanner pour reconnaître les *identificateurs* et les *constantes entières*.

Alphabet :

$$X = L \cup C$$

$$L = \{a, b, \dots, z\}$$

$$C = \{0, 1, \dots, 9\}$$

$$\text{mot } \omega \in X^*$$

$$\text{mot vide} = \lambda$$

Langage Ensemble de mots compris dans X^*

Expressions régulières caractérisent un langage régulier

Expression régulière c'est λ ou voir ci dessous :

Pour L_0 :

$$L_0 = l.(l + c)^* + c.c^* + (+).c.c^* + (-).c.c^*$$

$$L_0 = l.L_1 + c.L_2 + (+).L_3 + (-).L_3$$

Pour L_1 :

$$L_1 = (l + c)^*.\lambda$$

$\Rightarrow_{\text{Arden}}$

$$L_1 = (l + c).L_1 + \lambda$$

Pour L_2 :

$$L_2 = c^* \equiv c^*.\lambda$$

$\Rightarrow_{\text{Arden}}$

$$L_2 = c.L_2 + \lambda$$

Pour L_3 :

$$L_3 = cc^*$$

$$L_3 = c.L_2$$

2.2 Décorer l'automate fini avec des actions sémantiques

Pour calculer :

- La valeur demandée du nombre lu en entrée.
- La chaîne de caractères constituant l'identificateur reconnu

val fonction qui donne la valeur décimale correspondant au caractère lu.

carcours variable qui contient le caractère courant lu en entrée.

valeur variable qui doit contenir la valeur décimale de l'entrée lue.

$$\begin{aligned}A_1 &= \{valeur := val(carcour);\} \\A_2 &= \{valeur := valeur * 10 + val(carcour);\} \\A_3 &= \{\text{si } carcour = - \text{ alors } \{signe := -1\} \text{ sinon } \{signe := 1\}\} \\A_4 &= \{valeur := valeur * signe;\}\end{aligned}$$

2.3 Rappels

Il faut découper le texte en lexèmes(token, unités syntaxiques) pour que le scanner donne ça au *parser* afin de voir si ça forme une phrase correcte.

Un lexème ça peut être :

- identificateur
- mots clés réservés
- constantes numériques
- opérations

Il ne doit pas tenir compte des blancs, des retours à la ligne, des commentaires.

Le scanner c'est un *automate fini* construit rigoureusement à partir d'expressions régulières avec Arden. Il faut ensuite ajouter les *actions sémantiques* sur les transitions pour calculer les attributs.


Parfois on a besoin d'informations supplémentaires ; pour les identificateurs c'est la chaîne de caractères qui correspond au nom de variable, pour les constantes numériques c'est leur valeur.

2.4 Quelques problèmes à régler

2.4.1 Problèmes de reconnaissance

Si on a "let" en mot clé et on a un identificateur "lettre". On donne la *priorité* à l'unité syntaxique la plus longue. voir 2.2

FIGURE 2.2– Problème de reconnaissance



2.4.2 Table des Symboles (TDS)

Une Unité Syntaxique(US) est identifiée par un code et éventuellement "des infos". La table des symboles sert à ranger ces infos. L'entrée dans la TDS est calculée par une fonction de hashcode.

Exemple de hascode :

$$f('abc') = (code(a) + code(b) + code(c)) \bmod taille('abc') = @1$$

Mais cette fonction de calcul de hash peut entrainer des *collisions* :


$$f('abc') = f('bac')$$

2.4.3 Problème du recul

Si on a $<$, on sait que l'unité syntaxique c'est $<$. Mais si on tombe sur \leq on a une autre unité syntaxique ; \leq .

C'est pas un problème car on a vu qu'on privilegie l'US la plus longue. Si on tombe sur < 1 , il faut remettre 1 dans le flot d'entrée.

FIGURE 2.3– Problème du recul



2.5 La notion de surlangage

Parfois, il faut trouver un compromis entre automate et actions sémantiques

$$\begin{aligned} X &= \{a, b\} \\ L &= \{w \in X^* / |w|_a \leq 2\} \\ &= \{w \in X^* / |w|_a = 0\} \cup \{w \in X^* / |w|_a = 1\} \cup \{w \in X^* / |w|_a = 2\} \\ &= b^* + b^*ab^* + b^*ab^*ab^* \end{aligned}$$

Rappel : $+$ est l'opérateur d'union sur les expressions régulières

Pour L_0 :

$$\begin{aligned} L_0 &= b^* + b^*ab^* + b^*ab^*ab^* \\ &= b^*(\lambda + ab^* + ab^*ab^*) \\ &= r1^*r2 \\ \Rightarrow^{Arden} L_0 &= bL_0 + \lambda + ab^* + ab^*ab^* \\ &= bL_0 + aL_1 + \lambda \end{aligned}$$


Pour L_1 :

$$\begin{aligned} L_1 &= b^* + b^*ab^* \\ &= b^*(\lambda + ab^*) \\ &= r1^*(\lambda + ab^*) \\ \Rightarrow^{Arden} L_1 &= bL_1 + \lambda + ab^* \\ L_1 &= bL_1 + aL_2 + \lambda \end{aligned}$$

Pour L_2 :

$$\begin{aligned} L_2 &= b^*.\lambda \\ L_2 &= r1^*.r2 \\ \Rightarrow^{Arden} L_2 &= bL_2 + \lambda \end{aligned}$$

FIGURE 2.4– Automate résultat



Rappel théoreme d'Arden :

$$\begin{aligned}
 X &= r1.X + r2 \\
 \Leftrightarrow X &= r1^*r2 \\
 \text{Si } \lambda &\notin r1 \text{ la solution est unique.}
 \end{aligned}$$


Imaginons maintenant qu'on veuille reconnaître ce langage là :

$$L = \{w \in X^* / |w|_a \leq 2012\}$$

On peut le reconnaître grace a un surlangage L' tel que $L \subseteq L'$ puis on contraint à L par des actions sémantiques.

$$\begin{aligned}
 L' &= X^* = (a + b)^* \\
 L' &= (a + b)^*.\lambda \\
 \Rightarrow^{Arden} L' &= (a + b)L' + \lambda \\
 &= aL' + bL' + \lambda
 \end{aligned}$$

FIGURE 2.5– Automate avec surlangage



Description des actions :

Listing 2.2– Action sémantique A0

```
NB_a := 0; //on initialise le nombre de 'a' a 0
```

Listing 2.3– Action sémantique A1

```
NB_a++; //on a trouve un 'a'
```

Listing 2.4– Action sémantique A2

```
if (NB_a <= 2012) then
  return (NB_a);
else
  ERROR ("Trop de a");
```

2.5.1 Pour automatiser les scanners

Il existe des outils pour générer automatiquement des scanners.

- lex
- flex
- ocamllex

On donne l'expression régulière et les actions sémantiques écrites en C ou en Ocaml

2.6 Rappels sur les grammaires

Un langage, plusieurs grammaires ? Voici quelques exemples :

$$\begin{aligned}
 G_1 : \\
 & S \rightarrow aAc \\
 & A \rightarrow Abb \\
 & A \rightarrow b \\
 G_2 : \\
 & S \rightarrow aAc \\
 & A \rightarrow bAb \\
 & A \rightarrow b \\
 G_3 : \\
 & S \rightarrow aAc \\
 & A \rightarrow bbA \\
 & A \rightarrow b
 \end{aligned}$$

Par intuition, on peut trouver les 3 expressions régulières :

- $L(G_1) = ab(bb)^*c$
- $L(G_2) = a(b^nbb^n)c$ avec $n \geq 0$
- $L(G_3) = a(bb)^*bc$

On peut en conclure que $L(G_1) = L(G_2) = L(G_3) = ab^{2n+1}c$

Formellement on sait résoudre des équations de langages.

- Passer de la grammaire à un système d'équations de langage.

$$A \rightarrow \alpha_1 | \alpha_2 | \dots | \alpha_n \equiv A = \alpha_1 + \alpha_2 + \dots + \alpha_n$$

- Résoudre un système d'équations de langage :

Pour G_1 :

$$\begin{aligned} G_1 &\equiv S = aAc \\ A &= Abb + b \\ \Rightarrow^{Ardenbis} A &= b(bb)^* \\ S &= ab(bb)^*c \end{aligned}$$

Pour G_2 :

$$\begin{aligned} G_2 &\equiv S = aAc \\ A &= bAb + b \\ \Rightarrow^{A^n B^n} A &= b^n bb^n (A^n B^n) \\ S &= ab^n bb^n c \end{aligned}$$

Pour G_3 :

$$\begin{aligned} G_3 &\equiv S = aAc \\ A &= bbA + b \\ \Rightarrow^{Arden} A &= (bb)^*b \\ S &= a(bb)^*bc \end{aligned}$$

Rappels Arden :

$$X = r_1X + r_2 \Leftrightarrow X = r_1^*r_2$$

Rappels ArdenBis :

$$X = Xr_1 + r_2 \Leftrightarrow X = r_2r_1^*$$

Rappels $A^n B^n$:

$$X = YXZ + U \Leftrightarrow X = Y^n U Z^n, n \geq 0$$

2.7 Approximation successive

Mais quelques fois, pour trouver le langage engendré, on doit procéder par approximations successives. Prenons par exemple :

$$\begin{aligned} S &\rightarrow aSR | RS | cR \\ R &\rightarrow SaR | b \end{aligned}$$

$L(G) = S = ?$ Il faut trouver *le plus petit point fixe* qui est solution du système d'équations.

On a une équation de langage $X = f(X)$, il faut trouver X qui soit solution. On part de \perp ie $\perp \equiv \emptyset$. Ensuite, on applique par itération la fonction f .

$$\begin{aligned} f^1(\emptyset) &= E_1 \\ f^2(\emptyset) &= f(E_1) = E_2 \\ f^{n+1}(\emptyset) &= f(f^n(\emptyset)) = f(E_n) = E_{n+1} \end{aligned}$$

Exemple pour $A = bAb + b$:

$$\begin{aligned} i = 0 : & \emptyset \\ i = 1 : & f(\emptyset) = b.\{\emptyset\}.b + b = \{b\} = E_1 \\ i = 2 : & f^2(\emptyset) = f(E_1) = f(b) = bbb + b = b^3 + b = E_2 \\ i = 3 : & f^3(\emptyset) = f(f^2(\emptyset)) = f(b^3 + b) = b(b^3 + b)b + b = b^5 + b^3 + b = E_3 \end{aligned}$$

Appliqué à l'exemple ci dessus, ça donne :

$$\langle S, R \rangle = \langle \emptyset, \emptyset \rangle$$

Ce qui implique que $f(\langle S, R \rangle) = \langle aSR + RS + cR, SaR + b \rangle$

Ca fait donc :

$$\begin{aligned} i = 0 : & \langle \emptyset, \emptyset \rangle \\ i = 1 : & f^1 \langle \emptyset, \emptyset \rangle = \langle \emptyset, b \rangle \\ i = 2 : & f^2 \langle \emptyset, \emptyset \rangle = f \langle \emptyset, b \rangle = \langle cb, b \rangle \\ i = 3 : & f^3 \langle \emptyset, \emptyset \rangle = f \langle cb, b \rangle = \langle acbb + bcb + cb, cbab + b \rangle \end{aligned}$$

Rappel :

$$\forall L \subseteq X^*, L.\emptyset = \emptyset$$

Chapitre 3

Notion d'analyse syntaxique

Il s'agit de déterminer si un *mot* $\in L(G)$ et si oui, avec quelles règles de grammaire il est construit.

Soit G une grammaire, il existe un automate à pile qui *simule* G .
Etant donnée une grammaire $G = \langle N, X, P, S \rangle$, on sait construire un *automate à pile* de façon automatique qui reconnaît $L(G)$, avec *un seul état*, souvent *non déterministe*.

$$G = \langle N, X, P, S \rangle$$
$$P = A \rightarrow \beta, A \in N, \beta \in (N \cup X)^*$$

Automate à pile :

- q
- X : alphabet d'entrée
- $N \cup X$: alphabet de pile
- q : état initial
- S : fond de pile ; axiome
- \emptyset : ensemble d'états finaux
- δ : fonction de transition :
 - $\delta(q, \lambda, A) = (q, B) \forall A \rightarrow B \in P$
 - $\delta(q, x, x) = (q, \lambda) \forall x \in X$

Exemple :

Soit G_2 tel que :

$$S \rightarrow aAc \quad (3.1)$$

$$A \rightarrow bbA \quad (3.2)$$

$$A \rightarrow b \quad (3.3)$$

$$N = S, A \quad (3.4)$$

$$X = a, b, c \quad (3.5)$$

Avec δ tel que :

$$\delta(q, \lambda, S) = (q, aAc) \quad (3.6)$$

$$\delta(q, \lambda, A) = (q, bbA) \quad (3.7)$$

$$\delta(q, \lambda, A) = (q, b) \quad (3.8)$$

$$\delta(q, a, a) = (q, \lambda) \quad (3.9)$$

$$\delta(q, b, b) = (q, \lambda) \quad (3.10)$$

$$\delta(q, c, c) = (q, \lambda) \quad (3.11)$$

Analyse de la séquence *abbbbbc* :

ruban	pile	regle
$\lambda abbbbbc$	S	3.6
abbbbbc	aAc	3.9
$\lambda bbbbbc$	Ac	3.7
$\lambda bbbbbc$	bbAc	3.10
bbbbc	bAc	3.10
bbbc	Ac	3.7
bbbc	bbAc	3.10
bbc	bAc	3.10
λbc	Ac	3.8
bc	bc	3.10
c	c	3.11
<i>mot lu</i>	<i>pile vide</i>	

Donc le mot est reconnu.

L'analyse doit se faire en *une seule lecture* du ruban et de façon *déterministe*. Pour cela, on regarde k symboles sur le ruban pour pouvoir décider de façon *unique* de la règle à appliquer. Cette analyse efficace est appelée *analyse k-prédictive*

Rappel G_2 :

$$S \rightarrow aAc$$

$$A \rightarrow bbA$$

$$A \rightarrow b$$

On peut écrire un algo déterministe pour la reconnaissance de $\omega \in L(G_2)$

Listing 3.1– Algo reconnaissance de ω

```

Utiliser 3.6;
Utiliser 3.9 pour depiler "a";
while on voit "bb" sur le ruban, do:
    Utiliser 3.7;
    Utiliser deux fois 3.10 pour depiler les 2 "b";
end

```

Utiliser la regle 3.8 si on lit "bc";
 Utiliser la regle 3.10 pour depiler "b";
 Utiliser la regle 3.11 pour depiler "c";

On utilise des grammaires dites *augmentées* pour être sur de pouvoir regarder k symboles. On choisit $\$$ comme symbole de fin de mot et on ajoute la règle suivante :

$$S' \rightarrow S\k$

On prendra S' comme axiome.

On a fait de l'analyse *déscendante* : on part de l'axiome jusqu'aux feuilles. C'est à dire, on dérive le non terminal le *plus à gauche*.

$$\begin{aligned} S' \rightarrow S\$^k &\rightarrow aAc \rightarrow abbAc\$^k \\ &\rightarrow abbbbAc\$^k \\ &\rightarrow abbbbc\$^k \end{aligned}$$

On lit le mot de *gauche à droite*. Ceci est appelé l'analyse descendante $\sim LL(k)$ (Left)

Il existe aussi l'analyse ascendante : on part du mot pour retrouver l'axiome, c'est à dire *on réduit* le terminal le plus à droite. Dans tout les cas, $A \rightarrow \alpha$ se lit "A produit α " ou " α se réduit en A".

Exemple d'analyse ascendante $\sim LR(k)$:

$$\begin{aligned} &abbbbbc\$^k \\ &\nabla \\ &abbbbAc\$^k \\ &\nabla \\ &abbAc\$^k \\ &\nabla \\ &aAc\$^k \\ &\nabla \\ &S\$^k \end{aligned}$$

3.1 Analyse descendante

Reconnaître(ou pas) un mot $u \in X^*$ sur le ruban, On part de S' et on a la pile.

A un instant donné, on a travaillé et on a reconnu un préfixe ω de u , $\omega \in X^*$. Pour ça on a mis $A\alpha$ dans la pile, $A \in N$

A est le sommet de pile et $\alpha \in (N \cup X)^*$

Quelle règle faut-il appliquer ? Choisir de *façon déterministe*

$$\begin{aligned}
 S &\rightarrow^* wA\alpha \\
 A &\rightarrow \beta \in P \\
 \omega\beta\alpha &\rightarrow^* wx = u \\
 \omega &\text{ c'est le ruban, } A\alpha \text{ c'est la pile} \\
 u &\in X^* \\
 \omega &\in X^* \\
 x &\in X^* \\
 \alpha &\in (N \cup X)^*
 \end{aligned}$$

Donc :

$$\begin{aligned}
 first_k(x) &\in first_k(\beta\alpha) \\
 first_k(x) &\notin first_k(\gamma\alpha) \forall A \rightarrow \gamma \neq A \rightarrow \beta
 \end{aligned}$$

Une grammaire est $LL(k)$ ssi \forall règles :

$$\begin{aligned}
 A &\rightarrow \beta_1 \in P \\
 A &\rightarrow \beta_2 \in P \\
 &\vdots \\
 A &\rightarrow \beta_n \in P \\
 k.lookahead(A \rightarrow \beta_i) \cap k.lookahead(A \rightarrow \beta_j) &= \emptyset \\
 \forall i, j (i \neq j)
 \end{aligned}$$

3.2 $First_k$

Définition : soit $\alpha \in (N \cup X)^*$

$$\begin{aligned}
 first_k(\alpha) &= \{\omega \in X^* / |\omega| < k \text{ et } \alpha \rightarrow^* \omega \\
 &\text{ou } \alpha \rightarrow^* \omega\beta, \beta \in (N \cup X)^* \text{ si } |\omega| = k\}
 \end{aligned}$$

Calcul ;

$$\begin{aligned}
first_0(\alpha) &= \{\lambda\}, \forall \alpha \in (N \cup X)^* \\
k \geq 1 : first_k(\lambda) &= \{\lambda\} \\
first_k(x) &= \{x\}, \forall x \in X \\
first_k(u) &= u \text{ si } u \in X^* \text{ et } |u| \leq k \\
&= x \text{ si } u \in X^* \text{ et } u = xv, |x| = k \\
first_k(\alpha) &= first_k(X_1)first_k(X_2)...first_k(X_n) \\
\text{si } \alpha &= X_1X_2...X_n \forall X_i \in (X \cup N)
\end{aligned}$$

Exemple pour $L(G_1) = a^ncb^n\$^k, n \geq 0$

$$\begin{aligned}
S' &\rightarrow S\$^k \\
S &\rightarrow aSb \\
S &\rightarrow c
\end{aligned}$$

Calcul de $first_1$:

$$\begin{aligned}
first_1(S') &= first_1(S\$^k) \\
&= first_1(first_1(S)first_1(\$^k)) \\
&= first_1(S) \\
first_1(S) &= first_1(aSb) + first_1(c) \\
&= \{a, c\} \\
&= \{a\} + \{c\}
\end{aligned}$$

Calcul de $first_2$:

$$\begin{aligned}
first_2(S') &= first_2(S\$^k) \\
&= first_2(first_2(S)first_2(\$^k)) \\
first_2(S) &= first_2(aSb) + first_2(c) \\
&= first_2(first_2(a)first_2(S)first_2(b)) + \{c\} \\
&= afirst_1(first_2(S)first_2(b)) + \{c\} \\
&= a(\{a\} + \{c\}) + \{c\} \\
&= \{aa, ac, c\}
\end{aligned}$$

Calcul de $first_3$:

$$first_3(S) = \{c, acb, aaa, aac\}$$

3.3 *Follow_k*

Definition :

Soit $A \in N$,

$$\text{follow}_k(A) = \{\omega \in X^*/S' \rightarrow^* uA\alpha, u \in X^*, \alpha \in (N \cup X)^*, \omega \in \text{first}_k(\alpha)\}$$

$$\text{follow}_k(S') = \{\lambda\} \forall k \geq 0$$

$$\text{follow}_k(Y) = \bigcup_{X \rightarrow \gamma Y \delta} \text{first}_k(\delta \text{follow}_k(X))$$

Exemple pour $L(G_1) = a^n cb^n \$^k, n \geq 0$

$$S' \rightarrow S \k$

$$S \rightarrow aSb$$

$$S \rightarrow c$$

Calcul de $follow_1$:

$$follow_1(S') = \{\lambda\}$$

$$follow_1(S) =$$

$$\text{r\`egle0} : S' \rightarrow S\k$

$$\begin{aligned} follow_1(S) &= first_1(\$^k follow_1(S')) \\ &= \{\$ \} \end{aligned}$$

$$\text{r\`egle1} : S \rightarrow aSb$$

$$\begin{aligned} follow_1(S) &= first_1(b follow_1(S)) \\ &= \{b\} \end{aligned}$$

$$\text{Donc} : follow_1(S) = \{\$, b\}$$

Calcul de $follow_2$:

$$follow_2(S) =$$

$$\text{r\`egle0} : S' \rightarrow S\k$

$$\begin{aligned} follow_2(S) &= first_2(\$^k \dots) \\ &= \{\$^2\} \end{aligned}$$

$$\text{regle1} : S \rightarrow aSb$$

$$\begin{aligned} follow_2(S) &= first_2(b follow_2(S)) \\ &= b first_1(follow_2(S)) \\ &= \{bb, b\$ \} \end{aligned}$$

3.4 *k.lookahead*

Définition :

$$\begin{aligned} &\forall A \in N, \\ &\forall A \rightarrow \beta \in P, \\ &\beta \in (N \cup X)^* \\ k.lookahead(A \rightarrow \beta) &= first_k(\beta follow_k(A)) \end{aligned}$$

Exemple sur G_1 :

$$\begin{aligned} 1.lookahead(S \rightarrow aSb) &= first_1(aSb follow_1(S)) = \{a\} \\ 1.lookahead(S \rightarrow C) &= first_1(cf follow_1(S)) = \{c\} \end{aligned}$$

3.5 $LL(k)$

Soit $G = \langle N, X, P, S \rangle$ et k un entier quelconque fixé.

$$\begin{aligned} G \text{ est } LL(k) \\ \Leftrightarrow \\ \forall A \in N, \forall A \rightarrow \beta \in P \\ \text{et } \forall A \rightarrow \gamma \in P, \\ \beta, \gamma \in (N \cup X)^* \\ k.lookahead(A \rightarrow \beta) \cap k.lookahead(A \rightarrow \gamma) = \emptyset \end{aligned}$$

G_1 est $LL(1)$

Exemple : sur G_2 :

$$\begin{aligned} S' &\rightarrow S\$^k \\ S &\rightarrow aAc \\ A &\rightarrow bbA \\ A &\rightarrow b \end{aligned}$$

$G_2 LL(?)$

$$L(G_2) = a(bb)^*bc\$^k = ab^{2n+1}c\$^k, n \geq 0$$

G_2 n'est surement pas $LL(0)$, est-elle $LL(1)$?

Montrons que G_2 n'est pas $LL(1)$ avec calcul des 1.lookhead. On ne s'intéresse qu'à A :

$$\begin{aligned} 1.lookahead(A \rightarrow bbA) &= first_1(bbA follow_1(A)) \\ &= \{b\} = E_1 \\ 1.lookahead(A \rightarrow b) &= first_1(b follow_1(A)) \\ &= \{b\} = E_2 \end{aligned}$$

$$E_1 \cap E_2 \neq \emptyset \Rightarrow G_2 \text{ n'est pas } LL(1)$$

Regardons si G_2 est $LL(2)$? On ne s'intéresse qu'à A :

$$\begin{aligned} 2.lookahead(A \rightarrow bbA) &= first_2(bbAfollow_2(A)) \\ &= \{bb\} = E_1 \\ 2.lookahead(A \rightarrow b) &= first_2(bfollow_2(A)) \\ &= bfirst_1(follow_2(A)) = E_2 \end{aligned}$$

$Follow_2(A)? \Rightarrow$ règles 1 et 2

$$\begin{aligned} follow_2(A) &= first_2(cfollow_2(S)) \\ &= cfirst_1(...) \\ \text{Donc } 2.lookahead(A \rightarrow b) &= \{bc\} \\ E_1 \cap E_2 &= \emptyset \\ \Rightarrow G_2 \text{ est } LL(2) \end{aligned}$$

3.6 Table d'analyse d'une grammaire $LL(k)$

On a une grammaire $G = \langle N, X, P, S' \rangle$

On a montré que G est $LL(R)$ en calculant $k.lookahead(A \rightarrow \beta) \forall A, \forall A \rightarrow \beta$
Maintenant on construit une *table d'analyse* M tq $M(mot, sommetdepile) =$
une *seule* action.

Si $\omega \in k.lookahead(A \rightarrow \alpha)$

G_2 est $LL(2)$

$$\begin{aligned} 2.lookahead(A \rightarrow bba) &= \{bb\} = E_1 \\ 2.lookahead(A \rightarrow b) &= \{bc\} = E_2 \\ 2.lookahead(S' \rightarrow S\$^k) &= first_2(S\$^k follow_2(S')) = \{ab\} \\ 2.lookahead(S \rightarrow aAc) &= first_2(aAc follow_2(S)) = afirst_1(A...) = \{ab\} \end{aligned}$$

Voici la table d'analyse correspondante :

	bb	bc	ab	$\2
S'			S\$,0	
S			aAc,1	
A	bbA,2	b,3		
a			pop	
b	pop	pop		
c				
\$				accept

Analysons un mot $\in L(G_2)$ avec la table :
le mot choisi est : *abbbbbc*\$

ruban	pile	action
abbbbbc\$	S'	0
abbbbbc\$	S\$	1
abbbbbc\$	aAc\$	pop
bbbbbc\$	Ac\$	
bbbbc\$	bbAc\$	
bbbc\$	Ac\$	2*pop
bbbc\$	bbAc\$	2
bc\$	Ac\$	2*pop
bc\$	bc\$	3
\$	\$	accept

Accept \Rightarrow mot *reconnu*

3.7 Résultats théoriques

- Toute grammaire $LL(k)$ n'est *pas* ambigüe \Leftrightarrow Grammaire ambigüe n'est pas $LL(K), \forall k \geq 0$
- Toute grammaire contenant *au moins* une règle *réursive à gauche* n'est pas $LL(k), \forall k$
- Une grammaire $LL(0)$ engendre un langage fini
- Tout *langage régulier* peut être engendré par une grammaire $LL(1)$

3.8 Procédures de descente récursive

3.8.1 Définitions

G grammaire $LL(1)$:

- Table d'analyse
- Procédures de descente récursive. Celles-ci doivent être dans un langage qui *supporte la récursivité*. \Rightarrow La pile de l'automate sera remplacée par la pile des appels récursifs.

Analyseur syntaxique $LL(1) \equiv$ ensemble de procédures.

Outils :

scan procédure pour appeler le scanner.

nexts *variable* qui contient l'unité syntaxique détectée par le scanner.

skip t : unité syntaxique.

Listing 3.2– procédure de skip

```
procedure SKIP(t:unite syntaxique) is
begin
```

```

    if (NEXTS == t) then SCAN
    else ERREUR();
end

```

A chaque non terminal $A \in N$, on lui fait correspondre une procédure.

Listing 3.3- procedure non terminal

```

procedure A is
begin
    image(beta)
end

```

telle que si $A \rightarrow \beta$, $\beta \in (N \cup X^*)$, $A \in N$ avec :

si $\beta = t \in X \Rightarrow image(\beta) = SKIP('t')$
 si $\beta = B \in N \Rightarrow image(\beta) = \text{appel à la procédure B}$
 si $\beta = \lambda \Rightarrow image(\beta) = \text{instruction vide} = NULL$
 si $\beta = \beta_1\beta_2...\beta_n \Rightarrow image(\beta) = image(\beta_1); image(\beta_2); ...; image(\beta_n);$

si :

$$\begin{aligned}
 &A \rightarrow \beta_1 \\
 &A \rightarrow \beta_2 \\
 &\dots \\
 &A \rightarrow \beta_n
 \end{aligned}$$

Listing 3.4- procedure A

```

Procedure A is
begin
    switch NEXTS
    1.lookahead(A -> beta_1): image(beta_1);
    1.lookahead(A -> beta_2): image(beta_2);
    ...;
    1.lookahead(A -> beta_n): image(beta_n);
    others: ERREUR;
end

```

3.8.2 Exemple

$$GN = \{S', S, A\}$$

$$X = \{a, b\}$$

$$S' \text{ axiome}$$

$$S' \rightarrow S\$$$

$$S \rightarrow aAs$$

$$S \rightarrow b$$

$$A \rightarrow a$$

$$A \rightarrow bSaA$$

LL(0) ? LL(1) ?

G est elle $LL(0)$?

Non car on a un choix pour S et pour A .

G est elle $LL(1)$?

oui.

Preuve pour S :

$$1. lookahead(S \rightarrow aAS) = \{a\}$$

$$1. lookahead(S \rightarrow b) = \{b\}$$

$$\{a\} \cap \{b\} = \emptyset$$

Preuve pour A :

$$1. lookahead(A \rightarrow a) = \{a\}$$

$$1. lookahead(A \rightarrow bSaA) = \{b\}$$

$$\{a\} \cap \{b\} = \emptyset$$

Procédures de descente récursive

Listing 3.5– procedure S'

```
procedure S' is
begin
  SCAN;
  S;
  SKIP(' $ ');
end
```

Listing 3.6– procedure S

```
procedure S is
begin
  switch NEXTS
  a: SKIP('a'); A; S;
  b: SKIP('b');
  others: ERREUR();
end
```

Listing 3.7– procedure A

```
procedure A is
begin
  switch NEXTS
  a: SKIP('a');
  b: SKIP('b'); S; SKIP('a'); A;
  others: ERREUR();
end
```

3.9 Eliminer la récursivité à gauche

Grammaire augmentée

Grammaire réduite on a éliminé tous les non terminaux inaccessibles depuis S' et tous les non terminaux improductifs

exemple :

$$S' \rightarrow S\$ \quad (3.12)$$

$$S \rightarrow aAbB \quad (3.13)$$

$$A \rightarrow aA \quad (3.14)$$

$$B \rightarrow bB|\lambda \quad (3.15)$$

$$C \rightarrow ac|\lambda \quad (3.16)$$

Ici, 3.15 est improductif et C est inaccessible depuis S' .

G *récursive à gauche* si il existe *au moins une règle* de P de la forme $A \rightarrow A\alpha$ donc on a aussi $A \rightarrow \beta$ pour arrêter.

Or une grammaire récursive à gauche n'est *PAS* $LL(k)$, $\forall k$, en particulier *PAS* $LL(1)$. Si on écrit la procédure correspondant au non terminal A .

$$A \rightarrow A\alpha$$

$$A \rightarrow \beta$$

Listing 3.8– procedure A

```

procedure A is
begin
  switch ...
    A // ca va boucler
  ...
end

```

3.9.1 Pour essayer d'éliminer la récursivité à gauche

$$A \rightarrow A\alpha$$

$$A \rightarrow \beta$$

$$\Leftrightarrow$$

Pour A :

$$A = A\alpha + \beta \Rightarrow^{Arden} A = \beta\alpha^*$$

$$A = \beta A'$$

Pour A' :

$$A' = \alpha^* \Rightarrow^{Arden} A' = \alpha A' + \lambda$$

Donc :

$$A = A\alpha + \beta \Leftrightarrow A = \beta A' \text{ et } A' = \alpha A' + \lambda$$

Ce qui donne :

$$A \rightarrow \beta A'$$

$$A \rightarrow \alpha A' | \lambda$$

Cette grammaire n'est *plus* récursive à gauche. Est-elle $LL(1)$? Si oui, on applique la procédure de descente récursive.

Exemple : soit G, récursive à gauche :

$$N = \{S', S, A\}$$

$$X = \{a, b\}$$

axiome : S'

$P : \{$

$$S' \rightarrow S\$$$

$$S \rightarrow SaA|A$$

$$A \rightarrow b$$

$\}$

$$L(A) = b$$

$$S = Sab + b \Rightarrow^{ArdenBis} L(S) = b(ab)^*$$

G' équivalente à G (càd $L(G) = L(G')$) et G' n'est plus récursive à gauche.

$$S = SaA + A = A(aA)^* \Rightarrow S = AS_1$$

$$S_1 = (aA)^* \Rightarrow^{Arden} S_1 = aAS_1 + \lambda$$

Donc G' donne :

$$S' \rightarrow S\$$$

$$S \rightarrow AS_1$$

$$S_1 \rightarrow aAS_1 | \lambda$$

$$A \rightarrow b$$

$$N' = \{S', S, A, S_1\}$$

G' est bien définie tel que $L(G) = L(G')$ et non récursive à gauche. G' est elle $LL(1)$? Pas de problème pour S' , S et A .

Calcul des *1.lookahead* pour S_1 :

$$1.lookahead(S_1 \rightarrow aAS_1) = \{a\}$$

$$\begin{aligned} 1.lookahead(S_1 \rightarrow \lambda) &= first_1(\lambda follow_1(S_1)) \\ &= \{\$ \} = E_2 \end{aligned}$$

$$\text{On a bien } \{a\} \cap \{\$ \} = \emptyset$$

Donc G' est $LL(1)$

Ecrivons les procédures de descente récursive pour G' :

Listing 3.9– procédure S'

```

procédure S' is
begin
  SCAN();
  S;
  SKIP(' $ ');
end

```

Listing 3.10– procedure S

```
procedure S is
begin
  A;
  S_1;
end
```

Listing 3.11– procedure S_1

```
procedure S_1 is
begin
  switch NEXTS
  a: SKIP('a'); A; S_1;
  $: NULL
  others: ERREUR();
end
```

Listing 3.12– procedure A

```
procedure A is
begin
  SKIP('b');
end
```

Chapitre 4

Génération de code

4.1 Introduction

On veut traduire les instructions du langage de haut niveau L_1 dans un langage intermédiaire *plus proche* du langage cible. On a 3 langages.

- Pour L_1 c'est un langage impératif composé de l'affectation, et toutes les structures de contrôle (if, else, case, switch, ...) et des boucles (for, while, repeat, ...)
 - Pour L_2 (langage intermédiaire) on prend un langage de quadruplets. (*choix*)
 - Pour σ , on va utiliser un langage *impératif* style ADA, Pascal
- Traduction σ tq \forall programme P , \forall donnée $PD \equiv \sigma(P)D$

4.2 Langage intermédiaire des quadruplets

Langage cible intermédiaire, ne ressemblant pas à vraiment assembleur. Les opérations se font directement en mémoire, pas de registres. Un quadruplet = instructions à 4 champs dont 3 adresses mémoire. operation, operande1, operande2, resultat.

On peut faire l'affectation, les operations arithmetiques, les branchements conditionnels ou inconditionnels.

Affectation (:=, d, nil, e)

Opération arithmétique (+, a, b, c)

Branchement inconditionnel (goto, nil, nil @)

Listing 4.1– Exemple de quadruplets

```
@i      +, a , b , t1  // t1 := a + b
@i+1    *, t1, c , t2  // t2 := t1 * c
@i+2    :=, t2 , nil, d  // d:= t2
```

```
@i+3  >?,a,b,alpha1 // si a > b alors aller en alpha1
      sinon faire suivant
@i+4  ...
alpha2 goto,nil,nil,@i+3
```

4.3 Actions sémantiques couplées à l'analyseur descendant

L'analyseur syntaxique c'est le chef d'orchestre. Il est *descendant* et *LL(1)*. Il s'occupe de l'AL (Analyse Lexicale) et de faire les actions sémantiques.

- Il va engendrer un programme *équivalent* en *quadruplets*. Il n'y a *PAS D'EXECUTION*.
- Pour ça on va avoir besoin d'informations à *mémoriser* ou à *modifier*.
- Les procédures de descente récursive vont avoir besoin de paramètres en entrée ou en sortie et de variables locales.

Exemple :

Les expressions arithmétiques définies par la grammaire suivante :

$$\begin{aligned} E &\rightarrow T\{+T\}^* \\ T &\rightarrow F\{*F\}^* \\ F &\rightarrow \text{ident} \mid (E) \end{aligned}$$

Notons que le symbole * sert ici pour le langage et pour définir l'opérateur de multiplication.

Listing 4.2– Procedure E

```
Procedure E is
begin
  T;
  while NEXTS = '+' loop
    SKIP('+');
    T;
    /* => engendre un quadruplet boite a outils
    GEN(QUAD: String);
    //engendre le prochain quadruplet (A,B,C,D)
    GEN("+,?,?,?");
  endloop
end // E
```

Il faut ajouter des arguments aux procédures *E* et *T*.

$$E \rightarrow T\{+T\}^*$$

Listing 4.3– Procedure E avec arguments

```

Procedure E (out r :String) is
  u, t :String;
begin
  T(r);
  while NEXTS = '+' loop
    SKIP('+');
    T(t);    //2e operande
    u := NEWTEMP;
    GEN("+", "^r^", "^t^", "^u"); // ^ est la
      concatenation de chaines
    r := u;
  endloop
end //E

```

NEWTEMP permet de créer une variable temporaire.

$$T \rightarrow F\{*F\}^*$$

Listing 4.4– Procedure T avec arguments

```

Procedure T (out r :String) is
  t :String;
begin
  F(r); //1e operande
  while NEXTS = '*' loop
    SKIP('*');
    F(t); //2e operande
    u := NEWTEMP;
    GEN("*", "^ r ^", "^ t ^", "^ u");
    r := u;
  endloop
end //T

```

$$F \rightarrow \text{ident}|(E)$$

Listing 4.5– Procedure F

```

Procedure F (out r :String) is
begin
  switch NEXTS:
    'ident':
      r:= ident.string;
      SCAN;
    '(':

```

```

SKIP ( ' ( ' ) ;
E ( r ) ;
SKIP ( ' ) ' ) ;

others:
    ERREUR ( ) ;
end

```

L'analyseur lexical a trouvé comme prochaine US un 'ident' et il a construit la chaîne de caractères qui constitue l'identificateur : cet attribut sémantique est accessible à *ident.string*.

4.4 Methodologie pour la traduction des structures de controle

Traduction dirigée par la syntaxe, en *un seul* passage(lecture) du programme. Pour le moment, l'analyseur est descendant *LL(1)*.

Il y a 3 étapes :

- Donner le schéma en quadruplets correspond à la structure de controle traduite. Donner la sémantique de la structure de controle en quadruplets. ie, ce qu'on *veut obtenir*
- Donner l'inventaire des *problèmes* qui peuvent apparaître et leurs *solutions*
- Ecrire les *procédures de traduction* pour obtenir le schéma en quadruplets, ie comment on fait pour y arriver.

Pour ça, on a la boîte à outils.

4.4.1 Rappels

Listing 4.6– Procédures connues

```

<statlist> ::= <inst> <suite>
<suite>    ::= ; <statlist> | lambda
<inst>     ::= <ifstat> | <whilestat> | <repeatstat>
            | <casestat> | ...

```

On a les procédures STATLIST, SUITE, INST. INST est un gros aiguillage suivant NEXTS.

Par exemple :

```

if appel de IFSTAT
while appel de WHILESTAT
:::

```

case appel de CASESTAT

4.4.2 Exemple de traduction sur ifstat

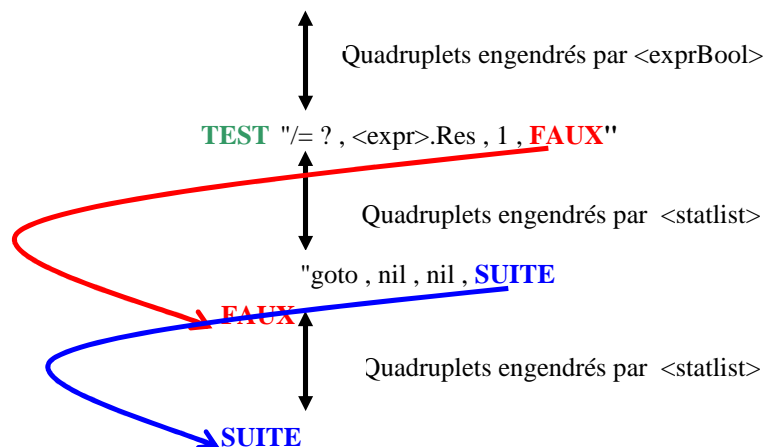
Listing 4.7– ifstat

```
<ifstat> ::= if <exprBool> then <statlist> else <
statlist> endif
```

Schema en quadruplets équivalent à <ifstat>

FIGURE 4.1– Schéma en quadruplets du if

Schéma en quadruplets correspondant au if



Problèmes et solutions

- Il faut vérifier le type. Vérifier que la variable qui contiendra le résultat de <expr> est de type *booléen*
 ⇒ solution : procédure CHECKTYPE (S : string, T : type)
- Référence en avant à FAUX et à SUITE. On engendre un quadruplet *incomplet* en mettant nil à la place de l'adresse(@). Ensuite, on mémorise l'@ du quadruplet incomplet dans une *variable*. Une fois qu'on connaît la bonne adresse, on met à jour le champ @ du quadruplet

incomplet. Pour mettre à jour, on utilise BACKPATCH(L : liste de quadruplets, A : int) ou A est une adresse de quadruplet.

Ecriture des procédures de traduction

Listing 4.8– procedure IFSTAT

```
procedure IFSTAT is
  Res :String;
  Test: Integer;  //@ de quadruplet
begin
  SKIP('if');
  EXP(Res);
  CHECKTYPE(Res, Boolean);
  SKIP('then');
  Test := NEXTQUAD; //memoriser l'@ du quad
    incomplet
  GEN("/=?", "^ Res ^", "^ 1 ^", nil); //engendre
    quad incomplet
  STATLIST;
  Suite := NEXTQUAD; //memorise @ du quad incomplet
  GEN("goto, nil, nil, nil"); //engendre 2e quad
    incomplet
  SKIP('else');
  BACKPATCH([Test], NEXTQUAD) // mise a jour du
    champ @ du quad incomplet Test avec l'@ du
    prochain quadruplet
  STATLIST;
  BACKPATCH([SUITE], NEXTQUAD) // maj du champs @ du
    quad incomplet Suite avec l'@ du prochain
    quadruplet.
  SKIP('endif');

end //IFSTAT
```

Traduction – Dirigée par la syntaxe. L'analyseur $LL(1)$ coordonne.

- en *un seul* passage
- On obtient un programme en quadruplets

Methodologie – Schéma équivalent en quadruplets

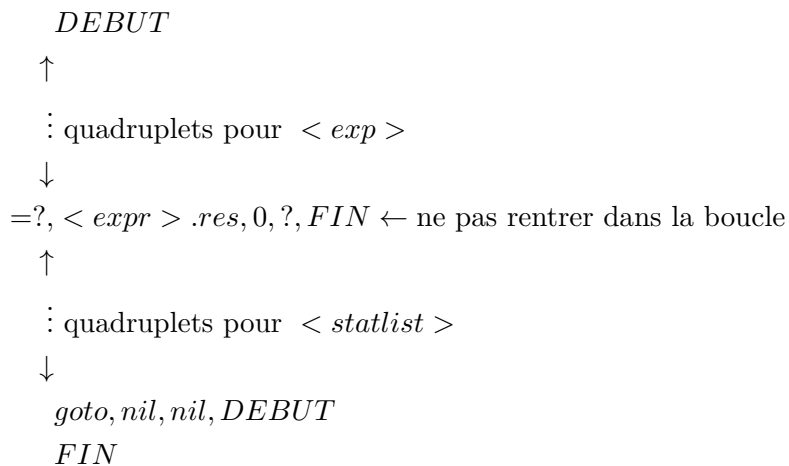
- Problèmes pour les actions sémantiques de la solution
- Mise en oeuvre avec les procédures de traduction(boite à outils)

4.4.3 Exemple de traduction sur whilestat

Listing 4.9– whilestat

```
<whilestat> ::= while <exprBool> loop <statlist>
               endloop
```

Schéma équivalent



Problèmes liés à la solution

Vérification de type vérifier que $\langle expr \rangle.res$ est de type Boolean. On peut utiliser *CHECKTYPE* pour ça.

Référence en avant à FIN – Engendrer un quadruplet *incomplet* c'est à dire qu'on met nil dans le champs adresse.

- Mémoriser l'adresse de ce quadruplet incomplet dans une variable *TEST*
- Mettre à jour le champ adresse du quad incomplet *TEST* qui connaît l'adresse *FIN*. On utilise *BACKPATCH*.

Référence en arrière à DEBUT – Mémoriser l'adresse de quadruplet *DEBUT* avant de l'engendrer dans une variable *DEBUT*

Procédure de traduction

Listing 4.10– procedure WHILESTAT

```
procedure WHILESTAT is
  DEBUT, TEST: Integer;
  Res: String;
begin
```

```

SKIP('while');
DEBUT := NEXTQUAD; //memoriser @ debut
EXP(Res);
CHECKTYPE(Res, bool); //verif que expr.res est
    bool
SKIP('loop');
TEST := NEXTQUAD; //memoriser @ fin
GEN("=?, "^Res^", 0, nil"); //engendrer un quad
    incomplet avec nil
STATLIST:
SKIP('endloop');
GEN("goto, nil, nil, "^str(DEBUT)); //str: itoa (
    integer to ascii)
BACKPATCH([TEST], NEXTQUAD); //maj du quad
    incomplet
end //whilestat

```

4.4.4 Traduction de déclarations

Définitions :

Listing 4.11– declaration

```
<declaration> ::= ident : <element>
```

Listing 4.12– element

```
<element> ::= Integer | array[Integer] of <element>
```

Exemples :

Listing 4.13– exemples de declarations

```

i: Integer;
j: Integer;
r: Integer;
T: array[10] of Integer;
tab: array[10] of array[20] of array[3] of [integer];

```

Ici, il n'y a pas de génération de quadruplets. Mais il faut *ranger les infos* issues de la déclaration dans la Table Des Symboles (TDS). Les informations à stocker sont :

- symbole (chaîne de caractère correspondant au nom de variable)
- type (ici : Integer, Array, ...)
- taille de l'information (pour Integer : 1, Pour un tableau : dimensions, ...)
- ...

Exemple de table de symboles :

symbole	type	taille
i	int	1
t	vector	10
none	int	1
tab	vector	10 * 20 * 3 * 1
none	vector	20 * 3 * 1
none	vector	3 * 1
none	int	1

Opérations sur la TDS

Listing 4.14- Operations sur la TDS

```
ENTER(S: String, P: out Integer);
SEARCH(S: String, P: out Integer);
CANCEL(S: String);
```

Accès à la TDS :

Listing 4.15- Operations sur la TDS

```
TDS[P].nomAttribut
```

Par convention, le premier indice de la TDS est 1. De plus, *on ne veut pas* plusieurs déclarations de même nom, même si type différent. Ça implique qu'il faut vérifier à chaque declaration si le symbole est déjà existant dans la TDS. Pour ça, on utilise *SEARCH*. Si *SEARCH* renvoie 0, alors l'entrée n'existe pas. Sinon, il y a *ERREUR*

Listing 4.16- Procedures DECLARATION et ELEMENT

```
procedure DECLARATION is
P: Integer;
taille: Integer;
begin
  if NEXTS != 'ident' then ERREUR();
  else
    SEARCH(NEXTS.String, P);
    if (P != 0) then ERREUR();
    else //pas encore dans TDS
      ENTER(NEXTS.String, P);
      SKIP(':');
      ELEMENT(P,taille);
    endif
  endif
endif
```

```
end //DECLARATION

procedure ELEMENT is
begin
  switch NEXTS
  'Integer' :
    TDS[P].type := int;
    TDS[P].taille := 1;
    taille := 1;
    SCAN;
  'array' :
    SKIP('array');
    SKIP('[');
    TDS[P].type := vector;
    if NEXTS != 'number' then ERREUR();
    else
      nbreElem := NEXTS.Valeur;
      SKIP(']');
      SKIP('of');
      ELEMENT(P+1,taille);
      taille := nbreElem * taille;
      TDS[P].taille := taille;
    endif
  others:
    ERREUR();
end //ELEMENT
```

L'analyseur lexical si il trouve un :

identificateur US ident et un attribut string qui contient la chaine de caractères constituant l'ident

entier attribut valeur qui contient la valeur decimale de l'entier reconnu.

4.4.5 Conclusion sur les actions sémantiques couplées avec analyse syntaxique $LL(1)$

- avantages
 - simple
 - souple(extensible)
 - pas de gestion de pile
- inconvénients
 - mélange action sémantiques et traitement de la syntaxe : ERREUR traite d'erreurs syntaxiques *et* sémantiques.
 - Difficulté d'optimisation

A présent, on va voir une approche ascendante grammaire $LR(1)$. Celle ci implique une gestion de pile plus importante, mais moins de traitement de syntaxe.

4.5 analyse ascendante

Jusqu'à là nous avons une grammaire $LL(1)$ qui faisait une analyse *descendante* avec des procédures de descente récursive.

Maintenant, grammaire $LR(1) \Rightarrow$ analyseur *ascendant* et déterminer où il faut mettre les actions sémantiques.

4.5.1 Définitions

On veut analyser un mot des terminaux vers l'axiome. (on "remonte" vers l'axiome). Dans G , si on a $A \rightarrow \beta \in P, A \in N, \beta \in (N \cup X)^*$

On avait :

A se dérive en β :

$$\begin{array}{c} A \\ | \\ \beta \end{array}$$

là on a :

β se réduit en A :

$$\begin{array}{c} \beta \\ \nabla \\ A \end{array}$$

Faire de l'analyse ascendante d'un mot $\omega \in L(G)$ c'est partir des terminaux de ω , reconnaître des manches pour les réduire en non terminaux et ça jusqu'à à l'axiome S'

On lit le mot de *gauche*(LL : Left) à droite et on dérive le non terminal le plus à droite(LR : Right).

4.5.2 Exemple

$$G = \langle \{a, b, c\}, \{S, S'\}, P, S' \rangle$$


$P :$

$$S \rightarrow^0 S\$$$

$$S \rightarrow^1 aSbS$$

$$S \rightarrow^2 c$$

FIGURE 4.2– Analyse de $\omega = acbacbc\$$



$$\begin{aligned}
 S' &\Rightarrow S\$ \Rightarrow aSbS\$ \Rightarrow aSbaSbS\$ \\
 &\Rightarrow aSbaSbc\$ \\
 &\Rightarrow aSbacbc\$ \\
 &\Rightarrow acbacbc\$
 \end{aligned}$$

L'ordre "chronologique" de réduction correspond à l'ordre des dérivation du non terminal le plus à droite.

4.5.3 automatiser ce type d'analyse

Pour faire "automatiquement" ce type d'analyse

- On a les règles de P
- On a le mot sur le ruban
- On a la pile de l'automate

Il faut que l'analyse soit *déterministe*.

Analyseur k.prédicatif regarder k symboles sur le ruban pour décider. Nous on se contente de k=0 ou k=1.

Exemple

$P :$

$$S \rightarrow S\$$$

$$S \rightarrow aSbS$$

$$S \rightarrow c$$

pile	sommet	ruban	action
		acbabc\$	Decaler 'a'
	a	cbabc\$	Decaler 'c'
a	c	bacbc\$	Reduire 2
	∇		
a	S	bacbc\$	Decaler 'b'
aS	b	acbc\$	Decaler 'a'
aSb	a	cbc\$	Decaler 'c'
aSba	c	bc\$	Reduire 2
aSba	S	bc\$	Decaler 'b'
aSbaS	b	c\$	Decaler 'c'
aSbaSb	c	\$	Reduire 2
aSbaSb	S	\$	Reduire 1
aSb	S	\$	Reduire 1
S	S	\$	Decaler '\$'
S	\$		ACCEPT

Actions :

SHIFT décalage du premier symbole lu du ruban au sommet de pile

REDUCE reconnaître un manche β en sommet de pile et le réduire en A
si $A \rightarrow \beta$

ACCEPT accepter le mot lu si on trouve S' au sommet de pile

Conflits**SHIFT/REDUCE** On ne sait pas décider si il faut réduire ou décaler**REDUCE/REDUCE** On ne sait pas décider quelle réduction on doit appliquer.

Pour décider de façon déterministe, on doit anticiper et regarder k symboles sur le ruban. Pour construire un analyseur ascendant $LR(k)$, il faut calculer des *classes d'items* (algorithme) et pour les grammaires $LR(1)$, il existe des outils qui engendrent *automatiquement* l'analyseur $LR(1)$: YACC, OCAMLYACC, BISON, ...

4.5.4 Exemple d'analyseur $LR(1)$

$$L = ab^{2n+1}c, n \geq 0$$

 $G_1 :$

$$\begin{aligned} S' &\rightarrow^0 S\$ \\ S &\rightarrow^1 aAc \\ A &\rightarrow^2 Abb \\ A &\rightarrow^3 b \end{aligned}$$

 $G_2 :$

$$\begin{aligned} S' &\rightarrow^0 S\$ \\ S &\rightarrow^1 aAc \\ A &\rightarrow^2 bAb \\ A &\rightarrow^3 b \end{aligned}$$

 $G_3 :$

$$\begin{aligned} S' &\rightarrow^0 S\$ \\ S &\rightarrow^1 aAc \\ A &\rightarrow^2 bbA \\ A &\rightarrow^3 b \end{aligned}$$

On prends $\omega = abbbbbc\$$

Pour G_1

pile	ruban	action
	abbbbbc\$	Decaler 'a'
a	bbbbbc\$	Decaler 'b'
ab	bbbbc\$	Reduire 3
aA	bbbbc\$	
aAb	bbbc\$	Decaler 'b'
aAbb	bbc\$	Decaler 'b'
aA	bbc\$	Reduire 2
aAb	bc\$	Decaler 'b'
aAbb	c\$	Decaler 'b'
aA	c\$	Reduire 2
aAc	\$	Decaler 'c'
S	\$	Reduire 1
S		Decaler '\$'
S\$		Reduire 0
S'		ACCEPT

Listing 4.17– Algo de reconnaissance

```

Decaler 'a'
Decaler 'b' et Reduire b en A // (3)
while on lit 'b' do
  Decaler 'b'
  Decaler 'b'
  Reduire "Abb" en A // (2)
endloop
Decaler 'c'
Reduire "aAc" en S // (1)
Decaler $
Reduire S$ en S' // (0)

```

Pour G_3

pile	ruban	action
	abbbbbc\$	D
a	bbbbbc\$	D
ab	bbbbc\$	D
abb	bbbc\$	D
abbb	bbc\$	D
abbbb	bc\$	D
abbbbb	c\$	D
abbbbA	c\$	Réduire b en A
abbA	c\$	Réduire bbA en A
aA	c\$	Réduire bbA en A
aAc	\$	Decaler 'c'
...

Ici, on a du prendre une décision entre "Reduire b en A" ou "Decaler b". On prends $k = 1$. On peut décider en regardant un symbole sur le ruban : on décale 'b' tant qu'on voit 'b' sur le ruban et on commence à réduire quand on voit 'c' sur le ruban. Pour G_3 , l'algo est déterministe si on regarde un symbole sur le ruban : $LR(1)$

Pour G_2

Il faut décaler 'b' jusqu'au b *du milieu* avant de commencer à réduire. On *ne sait pas* décider même en regardant k symboles si il faut réduire le sommet de pile en A ou bien décaler le prochain b. G_2 n'est PAS $LR(k), \forall k$

4.6 Piles syntaxiques et sémantiques

On a une grammaire $LR(1)$ et son analyseur *ascendant* (construit automatiquement avec YACC par ex.) On veut coupler les actions sémantiques (génération de quadruplets). Le problème c'est de savoir où mettre ces actions. \Rightarrow mettre les actions sémantiques (du code à exécuter) au moment de la *réduction d'un manche*.

Pile syntaxique :

$$\alpha\beta_1\beta_2...\beta_n \text{ et on a } A \rightarrow \beta_1, \beta_2, ..., \beta_n \in P$$

$$\nabla$$

$$\alpha A$$

Où trouver les informations nécessaires?. Il faut piocher ça dans les *piles sémantiques*. On prend *une pile sémantique* par *info à conserver* (attribut à conserver)

Les piles sémantiques sont gérées en même temps que la pile syntaxique et les attributs sont associés à *chaque non terminal*

pile syntaxique	$\alpha\beta\beta_1\beta_2...\beta_n$	Note : $\beta_1 \dots \beta_n$ se réduit en un non terminal β à qui on associe un attribut sémantique dans le pile res.
pile sémantique res	$\beta.res$	
pile sémantique adr	...	

4.6.1 Exemple avec pile sémantique

Listing 4.18– whilestat

```
<whilestat> ::= while <exprBool> loop <statlist>
               endloop
```

Schéma équivalent

```

DEBUT
↑
: quadruplets pour < exp >
↓
= ?, < expr > .res, 0, ?, FIN ← ne pas rentrer dans la boucle
↑
: quadruplets pour < statlist >
↓
goto, nil, nil, DEBUT
FIN
```

Problèmes liées à la solution

Vérification de type vérifier que $\langle expr \rangle .res$ est de type Boolean. On peut utiliser *CHECKTYPE* pour ça.

Référence en avant à FIN – Engendrer un quadruplet *incomplet* c'est à dire qu'on mets nil dans le champs adresse.

- Mémoriser l'adresse de ce quadruplet incomplet dans une variable *TEST*
- Mettre à jour le champs adresse du quad incomplet *TEST* qui connaît l'adresse *FIN*. On utilise *BACKPATCH*.

Référence en arrière à DEBUT – Mémoriser l'adresse de quadruplet *DEBUT* avant de l'engendrer dans une variable *DEBUT*

Piles sémantiques

- pile des résultats de $\langle \text{expr} \rangle \Rightarrow$ pile *Res*
- pile des adresses(@) des quadruplets à conserver \Rightarrow pile *Adr*

Coupures ? si oui, ou ?

- on modifie la grammaire en ajoutant des règles factices. ($M \rightarrow \lambda$, $N \rightarrow \lambda$)

Solution

pile synt	while λ
pile res	
pile adr	

Listing 4.19– première étape

```
Reduire M -> lambda
Action sémantique {
  M.Adr := NEXTQUAD;
}
```

pile synt	while M $\langle \text{expr} \rangle$ loop λ
pile res	$\langle \text{expr} \rangle$.res
pile adr	M.adr

Listing 4.20– deuxième étape

```
Reduire N -> lambda
Action sémantique {
  N.Adr := NEXTQUAD;
  CHECKTYPE( $\langle \text{expr} \rangle$ .Res, bool);
  GEN("=?, " ^  $\langle \text{expr} \rangle$ .Res ^ ", 0, nil");
}
```

pile synt	while M $\langle \text{expr} \rangle$ loop N $\langle \text{statlist} \rangle$ endloop
pile res	$\langle \text{expr} \rangle$.res
pile adr	M.adr , N.adr

Listing 4.21– troisième étape

```
Reduire while ... endloop -> whilestat
Action sémantique {
  GEN("goto, nil, nil, " ^ str(M.Adr));
  BACKPATCH([N.Adr], NEXTQUAD);
}
```